

技术报告 · 2026 年 4 月

DeepSeek V4 发布 完整技术解读

两款开源 MoE 模型，原生百万 token 上下文，效率突破与前沿性能全面解析

1.6T

V4-Pro 总参数量

1M

原生上下文窗口

3,206

Codeforces 评分

27%

V4-Pro FLOPs(对比 V3.2)

来源: Fello AI

发布日期: 2026 年 4 月 24 日 · 版本预览

原文: felloai.com/deepseek-v4/

目录

概述

01	执行摘要	03
02	DeepSeek V4 是什么	03
03	V4 系列两款模型	04

架构与训练

04	重大架构革新	04
05	混合 CSA 与 HCA 注意力机制	05
06	训练数据、算力与优化器	05
07	基于在线策略蒸馏的后训练	06

性能评测

08	基准测试全景	07
09	智能体编程与工具使用	09
10	数学推理能力	09
11	百万 Token 上下文与效率	10
12	推理强度模式	11

部署与生态

13	华为昇腾支持与国产硬件	12
14	定价、API 与可用性	12
15	局限性与展望	13

| 执行摘要

2026 年 4 月 24 日，DeepSeek 发布 V4 系列预览版。这是首个从设计之初便以原生百万 token 上下文为默认能力的开源模型家族，同时在竞技编程、形式化数学和工具调用上创下开源模型新纪录。

93.5% LiveCodeBench (开源最高)	3,206 Codeforces 评分 (人类第 23)	9.5× KV 缓存缩减 (V4-Pro vs V3.2)	120/120 Putnam-2025 满分
--	--	---	--

本报告核心问题

1. V4 的架构创新如何实现百万 token 上下文的经济可行性？

2. V4-Pro-Max 与 GPT-5.4、Gemini 3.1 Pro、Claude Opus 4.6 的差距究竟在哪里？

3. 对开发者、智能体构建者和自托管团队，V4 的实际价值是什么？

核心结论

- V4 在竞技编程 (Codeforces 3,206) 和形式化数学 (Putnam-2025 120/120) 上与闭源前沿比肩，是首次做到这一点的开源模型。
- 混合 CSA/HCA 注意力机制将 1M token 推理的 FLOPs 降至 V3.2 的 27%，KV 缓存缩小至 10%，令长上下文智能体循环成为可生产工作负载。
- V4 落后于闭源前沿约 3-6 个月，在通用知识、超长上下文检索和纯智能体编程三个方向存在可量化的差距。

DeepSeek V4 是什么

DeepSeek V4 是 DeepSeek 第四代旗舰模型家族，取代将于 2026 年 7 月 24 日退役的 V3 和 V3.2 系列。

DeepSeek 是一家位于杭州的 AI 实验室，2025 年 1 月凭借低成本推理模型 R1 震动全球市场。V4 延续了这一路线，将目标锁定在下一个效率瓶颈——超长上下文处理。技术报告将此次发布定义为打破了“超长上下文处理的效率壁垒”，并将长上下文定位为继推理模型浪潮(R1、o1 系列)之后，测试时扩展的下一个核心维度。

两款 V4 模型均为开源，发布于 Hugging Face 的 DeepSeek 合集下。开发者可下载权重、本地运行并进行微调。API 同步上线，同时支持 OpenAI ChatCompletions 格式和 Anthropic API 格式，大幅降低迁移成本。

"首个从设计之初就以百万 token 上下文为默认能力(而非附加特性)的开放模型家族。"

— DeepSeek V4 技术报告, 2026 年 4 月

V4 系列两款模型

V4 系列以两种规格发布，均为混合专家架构(MoE)，覆盖从高性价比到极致性能的完整区间。

模型	总参数量	激活参数量	层数	路由专家数	训练 Token 数
DeepSeek-V4-Flash	2,840 亿	130 亿	43	256	32 万亿
DeepSeek-V4-Pro	1.6 万亿	490 亿	61	384	33 万亿

每个模型均有一个共享专家加上路由专家。前三个 MoE 层采用哈希路由(根据 token ID 的固定哈希分配专家)，其余层使用 DeepSeekMoE 学习路由。两款模型均启用深度为 1 的多 Token 预测(MTP)。

选型建议：V4-Flash(130 亿激活参数)适合高吞吐对话与推理；V4-Pro(490 亿激活参数)适合竞技编程、形式化数学及工具密集型智能体任务。两款均提供 Thinking / Non-Thinking 双模式与原生 1M 上下文。

| 重大架构革新

V4 最大的变化在于注意力机制——标准注意力的二次方计算成本已成为超长上下文处理的核心瓶颈，V4 用三项协同创新正面突破。

三项核心改进

1. 混合注意力机制(CSA + HCA)

结合压缩稀疏注意力(CSA)与重度压缩注意力(HCA)，分别负责精确检索与全局上下文感知，两类层在网络中交替排布。

2. 流形约束超连接(mHC)

对残差连接的升级设计，专为深层网络的数值稳定性优化，替代 V3 中的 DeepSeekMoE 残差结构。

3. Muon 优化器

取代 AdamW 用于大多数参数，在万亿参数规模下提供更快收敛速度和更稳定的训练过程。嵌入层、预测头和 RMSNorm 权重保留 AdamW。

其他继承特性

- DeepSeekMoE 细粒度路由与共享专家结构
- 大多数权重采用 FP8 精度；路由专家权重改用 FP4 存储，内存减半
- 128K 词汇量分词器，与 V3 完全兼容
- 多 Token 预测(MTP)，深度为 1

混合 CSA 与 HCA 注意力机制

V4 将标准注意力拆分为两个互补通道，在精度与全局感知之间动态权衡。

压缩稀疏注意力 (CSA)

沿序列维度对 KV 缓存进行压缩(压缩率 4)，应用 V3.2 引入的 DeepSeek 稀疏注意力。一个"闪电索引器"为每个查询从压缩 KV 中检索最相关的条目：

- V4-Pro: 选取前 1,024 个条目
- V4-Flash: 选取前 512 个条目
- 附加 128 token 滑动窗口，确保局部上下文不丢失

重度压缩注意力 (HCA)

采用 128 倍更激进的压缩率，然后对压缩表示执行全量密集注意力。每一层均可获得廉价的全局远距离 token 视角，无需额外 FLOPs。

设计权衡

CSA 提供精确稀疏检索(高精度，低覆盖)，HCA 提供廉价全局感知(低精度，全覆盖)。两者在网络每个深度交替出现，模型可按需在两种策略间动态路由，而非预先固定一种。

训练数据、算力与优化器

V4 在预训练规模上与 V3 持平，但在序列长度扩展策略和数值稳定性技术上有显著改进。

预训练规模

参数	V4-Flash	V4-Pro
训练 Token 数	32 万亿	33 万亿
最大批量	7,550 万 token	9,440 万 token
峰值学习率	2.7×10^{-4}	2.0×10^{-4}

序列长度扩展

训练分阶段递增上下文长度：4K → 16K → 64K → 1M。密集注意力运行前 1 万亿 token(Pro 更长)，之后在 64K 处引入稀疏注意力并保持至训练结束。

稳定性技术

- 预见性路由 (Anticipatory Routing)：在检测到 loss 尖峰时自动激活，将骨干网络与路由器更新解耦，用历史权重计算路由索引。
- SwiGLU 截断 (SwiGLU Clamping)：限制 SwiGLU 的线性和门控分量范围，稳定深层网络激活值。

基于在线策略蒸馏的后训练

V4 后训练流程与 V3 有根本差异：为每个领域(数学、编程、智能体任务、指令跟随等)独立训练一个专家模型，每个专家先经过有监督微调(SFT)，再用组相对策略优化(GRPO)强化学习。

最终统一模型通过在线策略蒸馏(OPD)训练——以学生身份最小化对所有专家教师的反向 KL 散度损失，将全域专长融合为一个连贯模型。这与 Kimi K2.6 等近期开源模型的后训练路线不谋而合。

DeepSeek 还构建了用于智能体 RL 的沙盒基础设施、可抢占的容错 rollout 服务，以及可在百万 token 上下文上运行 episode 的大规模 RL 框架——这些基础设施是长时程智能体任务能否规模化训练的真正门槛。

基准测试全景

DeepSeek 技术报告发布了 V4-Pro-Max 与主流闭源及开源模型的全面对比。

完整基准对比

蓝色加粗 表示该行最优值

基准测试	Opus 4.6	GPT-5.4	Gemini 3.1 Pro	Kimi K2.6	GLM-5.1	V4-Pro-Max
MMLU-Pro	89.1	87.5	91.0	87.1	86.0	87.5
SimpleQA-Verified	46.2	45.3	75.6	36.9	38.1	57.9
Chinese-SimpleQA	76.4	76.8	85.9	75.9	75.0	84.4
GPQA Diamond	91.3	93.0	94.3	90.5	86.2	90.1
HLE(无工具)	40.0	39.8	44.4	36.4	34.7	37.7
LiveCodeBench	88.8	-	91.7	89.6	-	93.5
Codeforces 评分	-	3,168	3,052	-	-	3,206
HMMT 2026 Feb	96.2	97.7	94.7	92.7	89.4	95.2
IMOAnswerBench	75.3	91.4	81.0	86.0	83.8	89.8
Apex	34.5	54.1	60.9	24.0	11.5	38.3
Apex Shortlist	85.9	78.1	89.1	75.5	72.4	90.2
MRCR 1M	92.9	-	76.3	-	-	83.5
CorpusQA 1M	71.7	-	53.8	-	-	62.0
Terminal Bench 2.0	65.4	75.1	68.5	66.7	63.5	67.9
SWE Verified	80.8	-	80.6	80.2	-	80.6
SWE Pro	57.3	57.7	54.2	58.6	58.4	55.4
SWE 多语言	77.5	-	-	76.7	73.3	76.2
BrowseComp	83.7	82.7	85.9	83.2	79.3	83.4
HLE(有工具)	53.1	52.0	51.6	54.0	50.4	48.2
GDPval-AA (Elo)	1,619	1,674	1,314	1,482	1,535	1,554
MCPAtlas Public	73.8	67.2	69.2	66.6	71.8	73.6
Toolathlon	47.2	54.6	48.8	50.0	40.7	51.8

三强横向对比解读

对比 Claude Opus 4.6

V4-Pro-Max 在 LiveCodeBench (93.5 vs 88.8)、IMOAnswerBench (89.8 vs 75.3)、Apex Shortlist (90.2 vs 85.9) 和 Toolathlon (51.8 vs 47.2) 上胜出。Opus 4.6 在知识类 (MMLU-Pro、GPQA Diamond、HLE)、长上下文检索 (MRCR 92.9 vs 83.5) 和 GDPval-AA 上占优。注：Anthropic 此后已发布 Opus 4.7，超越 Opus 4.6 所有指标。

对比 GPT-5.4

V4-Pro-Max 在 LiveCodeBench、Codeforces、Apex Shortlist 和 Toolathlon 上略胜。GPT-5.4 在 Terminal Bench 2.0(75.1 vs 67.9)和 GDPval-AA 上领先。注：OpenAI 此后发布 GPT-5.5, Terminal Bench 2.0 升至 82.7%，进一步拉开智能体编程差距。

对比 Gemini 3.1 Pro

V4-Pro-Max 在 LiveCodeBench、Codeforces、IMOAnswerBench、Apex Shortlist、CorpusQA 1M 和 Toolathlon 上全面胜出。Gemini 的优势集中于通用知识(SimpleQA-Verified 75.6、MMLU-Pro 91.0、GPQA Diamond 94.3)。

DeepSeek 在技术报告中直接描述：V4-Pro-Max "略低于 GPT-5.4 和 Gemini-3.1-Pro"，大约落后前沿水平三到六个月。对于可免费下载的开放权重模型，这是相较于 R1 一年前状态的一次意义重大的跃升。

| 核心能力：编程、数学与长上下文

智能体编程与工具使用

DeepSeek 明确指出 V4 已"与 Claude Code、OpenClaw、OpenCode 等主流 AI 智能体无缝集成", V4 正为其内部智能体编程提供动力, 发布公告中的示例 PDF 即由 V4-Pro 端到端生成。

基准测试	V4-Pro-Max	V4-Flash-Max
SWE-Bench Verified	80.6%	79.0%
SWE-Bench Pro	55.4%	-
SWE 多语言	76.2%	-
Terminal Bench 2.0	67.9%	56.9%
MCPAtlas Public	73.6%	-
Toolathlon	51.8%	-

V4-Flash-Max 在 Terminal Bench 2.0 上从 67.9% 降至 56.9%, 智能体任务应选 Pro; 对话和推理场景 Flash 更具性价比。DeepSeek 内部评估报告 V4-Pro-Max "优于 Claude Sonnet 4.5, 接近 Opus 4.5 水平"。

数学推理能力

形式化数学是 V4 最突出的领域之一。

测试	V4-Flash-Max	Seed-2.0-Pro	Gemini-3-Pro
Putnam-200 Pass@8	81.0	35.5	26.5

在结合非形式化推理与形式化验证的前沿 Putnam-2025 测试中, V4 达到满分 **120/120**, 与 Axiom 并列, 领先于 Aristotle(100/120)和 Seed-1.5-Prover(110/120)。HMMT 2026 年 2 月赛 95.2 分和 IMOAnswerBench 89.8 分, 使 V4-Pro-Max 接近 GPT-5.4 并在 IMOAnswerBench 上超越 Gemini 3.1 Pro。

| 百万 Token 上下文与效率

两款 V4 模型均原生支持 1M token 上下文，这是默认配置，不附加额外费用，也无需切换专属档位。

长上下文检索表现

在上下文检索基准测试 MRCC 上，V4-Pro 的准确率随长度递减但仍具竞争力：

上下文长度	V4-Pro 准确率
128K token 以内	94%
512K token	82%
1M token	66%

MRCC 1M 整体得分：V4-Pro 83.5，Gemini 3.1 Pro 76.3，Claude Opus 4.6 92.9。CorpusQA 1M(更贴近真实长文档问答)：V4-Pro 62.0%，优于 Gemini 3.1 Pro 的 53.8%。

效率突破

在 1M token 上下文下，V4 相对 V3.2 的效率提升数据：

模型	FLOPs(对比 V3.2)	KV 缓存(对比 V3.2)
DeepSeek-V4-Pro	27%(降低 3.7 倍)	10%(缩小 9.5 倍)
DeepSeek-V4-Flash	10%(降低 9.8 倍)	7%(缩小 13.7 倍)

实际意义

KV 缓存缩小 9.5 倍，意味着单块 GPU 可承载约 10 倍的并发长上下文会话，直接改变了智能体和研究工作负载的成本结构。在未来支持更快 FP4 计算的硬件上，DeepSeek 估计还能再提升三分之一。

推理强度模式

每款 V4 模型提供三个推理强度等级：Non-Think(非思考)、High(高)和 Max(最强)，通过 API 的 thinking mode 参数配置。

基准测试	Flash Non-Think	Flash High	Flash Max	Pro Non-Think	Pro High	Pro Max
MMLU-Pro	83.0	86.4	86.2	82.9	87.1	87.5
SimpleQA-Verified	23.1	28.9	34.1	45.0	46.2	57.9
GPQA Diamond	71.2	87.4	88.1	72.9	89.1	90.1
HLE	8.1	29.4	34.8	7.7	34.5	37.7
LiveCodeBench	55.2	88.4	91.6	56.8	89.8	93.5
HMMT 2026 Feb	40.8	91.9	94.8	31.7	94.0	95.2
Terminal Bench 2.0	49.1	56.6	56.9	59.1	63.3	67.9
SWE Verified	73.7	78.6	79.0	73.6	79.4	80.6
MRCR 1M	37.5	76.9	78.7	44.7	83.3	83.5

两点关键观察：

- 1. 推理模式的影响远大于模型规模：HLE 从 Pro Non-Think 的 7.7 飙升至 Pro Max 的 37.7，接近 5 倍提升。
- 2. Flash Max 性价比惊人：在给定足够思考预算后，Flash Max 在推理基准上非常接近 Pro Max，知识密集任务(参数量更关键)除外。

硬件生态、定价与部署

华为昇腾支持

与 V4 发布同期，华为宣布其搭载昇腾 950 芯片的超节点将开箱即用完全支持 DeepSeek V4，无需依赖受出口限制的美国 GPU。这折射出国产 AI 基础设施构建自主闭环技术栈的更广泛推进：国产模型、国产芯片、国产推理软件。

API 与模型 ID

API 用户无需更改 `base_url`，只需更新模型参数：

- V4-Pro: `deepseek-v4-pro`
- V4-Flash: `deepseek-v4-flash`

现有 `deepseek-chat` 和 `deepseek-reasoner` 端点将于 2026 年 7 月 24 日 15:59 UTC 后完全退役，开发者应在此日期前完成迁移。

三种获取渠道

渠道	说明	适合场景
<code>chat.deepseek.com</code>	专家模式 (Pro Max) / 即时模式 (Flash)	个人用户，无需账号变更
DeepSeek API	OpenAI / Anthropic 双格式，1M 上下文默认	开发者集成，生产部署
Hugging Face	开放权重，含完整技术报告 PDF	本地运行、微调、研究

定价预期：DeepSeek 尚未公布最终 API 定价。参考 V3 远低于 OpenAI/Anthropic 的历史售价，V4 预计大幅低于 GPT-5.5 的 \$5/\$30 和 Claude Opus 4.7 的 \$5/\$25 (每百万 token 输入/输出)。

局限性 与 行业影响

DeepSeek 自述的六项局限

局限	具体表现
架构复杂性	保留了大量 V3 组件以降低风险，架构"相对复杂"，未来版本将简化
训练稳定性	预见性路由和 SwiGLU 截断有效，但底层原理尚未充分理解
知识差距	MMLU-Pro、SimpleQA、GPQA Diamond、HLE 落后于 Gemini 3.1 Pro
长上下文检索上限	超过 128K token 后准确率下降，1M token 时 MRCR 降至 66%(Opus 4.6 为 92.9%)
前沿智能体任务	Terminal Bench 2.0(67.9) 和 SWE Pro(55.4) 仍落后于 GPT-5.5 和 Opus 4.7
文本限定	V4 不支持图像、音频或视频输入，多模态能力仍在开发中

对不同群体的价值

开发者与 API 用户

V4-Flash 是高吞吐服务的新默认选择。130 亿激活参数、百万 token 上下文、Max 模式推理能力接近 GPT-5.2，是市场上性价比最高的开源选项之一。V4-Pro 在竞技编程、工具密集型智能体工作流上可直接替换 Claude Opus。

开源与自托管团队

V4 是目前在竞技编程和形式化数学上最强的开源模型，首个在 Codeforces 上与闭源前沿比肩的开源模型，也是首个原生为百万 token 上下文构建的可广泛部署开源模型。对任何自建 LLM 技术栈的团队，V4 实质性地重置了"自建还是购买"的决策。

智能体构建者

CSA/HCA 效率提升将 1M token 智能体循环从研究演示转变为可落地生产的工作负载。长上下文 token 效率直接转化为更低的每任务成本和更长的每美元智能体运行时长。

总结判断

V4 是迄今最有力的证据，表明开源模型已缩小了与闭源前沿的大部分差距，同时在长上下文效率上建立了真正的架构领先优势。下一个问题不再是开源模型能否与前沿竞争，而是当百万 token 上下文成为常态后，它们能解锁什么——V4 是为回答这个问题而生的第一款模型。